

# Conducción Autónoma en Duckietown mediante Aprendizaje por Refuerzo profundo

Métodos Avanzados en Machine Learning

Adolfo Peña Marín

Junio 2026

## 1 Introducción y objetivo

El objetivo es entrenar un agente capaz de mantenerse en el carril en Duckietown a partir de observaciones de imagen y que **generalice** a un mapa no visto durante el entrenamiento. La nota depende del desempeño en el mapa oculto `Duckietown-loop_obstacles-v0`, con obstáculos estáticos.

**La entrega final es RL puro.** Siguiendo las diapositivas del reto, la solución es aprendizaje por refuerzo *de extremo a extremo*: la red recibe la imagen y produce directamente la acción de control (velocidades de rueda). **No** se entrega ningún controlador clásico, PID, heurística de avance forzado (`forward_turn`) ni *action mode* diseñado para conducir (maniobras discretas predefinidas o velocidades acotadas a mano). Esas variantes se exploraron como diagnóstico y se descartan por inyectar conocimiento de conducción.

**Contrato de evaluación.** El modelo debe (i) esperar observaciones de forma `(1, 64, 64)` apiladas en 4 frames  $\rightarrow (4, 64, 64)$ ; (ii) llevar definidas e importables las clases personalizadas (`CustomCNN`, `wrappers`); y (iii) cargar “a la primera” en un entorno limpio reconstruido desde `requirements.txt`. Entrenar en el mapa oculto supone descalificación: está bloqueado por `ValueError` en tres puntos del código.

**Fase 1 (calentamiento): Q-Learning tabular.** Como ejercicio previo se implementa Q-Learning tabular *sin librerías de Deep RL* sobre `FrozenLake-v1`  $8 \times 8$  resbaladiza (actualización de Bellman TD(0),  $\epsilon$ -greedy con decaimiento,  $\alpha = 0.1$ ,  $\gamma = 0.99$ , 50 000 episodios). La política greedy alcanza una **tasa de éxito**  $\approx 0.52$  (Figura 1); código en `q_learning_sandbox.py`. El resto de la memoria se centra en Duckietown.

## 2 Entorno y pipeline

**Duckietown real (gym-duckietown).** El simulador usa la API de *gym clásico* (0.25.2), no Gymnasium, por compatibilidad con `gym-duckietown` (daffy, 6.1.34). `DuckieWrapper` (`src/wrappers.py`) adapta esa API antigua (4-tupla) a Gymnasium (5-tupla) que espera Stable-Baselines3. El entorno real se confirma por consola: `[duckie_factory] Using real Duckietown env: ..., gym-duckietown version 6.1.34, using DuckietownEnv.`

**Observaciones.** Cada frame se procesa así:

RGB  $(480 \times 640 \times 3) \rightarrow$  recorte 50% superior (cielo)  $\rightarrow$  grises  $\rightarrow$  resize  $64 \times 64 \rightarrow (1, 64, 64)$  `uint8`,




Figure 1: Fase 1: media móvil (ventana 100) de la recompensa por episodio en **FrozenLake-v1** 8×8 resbaladiza; se estabiliza en torno a 0.45–0.50.

y tras `VecFrameStack(n_stack=4)` (`src/envs.py`)  $\rightarrow (4, 64, 64)$ . El apilado de 4 frames da percepción de velocidad y giro.

**Acción continua de ruedas.** La acción del simulador son las velocidades de las **dos ruedas**  $[v_{izq}, v_{der}] \in [-1, 1]^2$  (`action_mode=wheels`); la política las produce directamente, sin acotar.

**Arquitectura y algoritmos.** `CustomCNN` (`src/cnn.py`) es un extractor estilo *NatureCNN* (3 conv  $\rightarrow$  lineal a 256), común a los tres algoritmos. SB3 ya normaliza la imagen `uint8` a  $[0, 1]$  antes del extractor, por lo que la CNN **no** vuelve a dividir entre 255 (Sección 4). Se evalúan:

- **PPO** (on-policy, continuo): `lr= 3 · 10-4`, `n_steps= 2048`, `batch= 64`, `n_epochs= 10`, `γ = 0.99`, `λGAE = 0.95`, `clip= 0.2`. Base del modelo final.
- **DQN** (off-policy, discreto vía `DiscreteActionWrapper`): `lr= 10-4`, `buffer= 50k`, `learning_starts= 10k`, `batch= 32`.
- **SAC** (off-policy, máxima entropía, continuo): `lr= 3 · 10-4`, `buffer= 50k`, `batch= 256`, `τ = 0.005`, `ent_coef=auto`.

**Infraestructura.** El entrenamiento se realizó en Google Colab con `venv` Python 3.11 (subproceso), `xvfb-run + MPLBACKEND=Agg`, y el orden ***model-first*** (`--init-order model-first`) para evitar un *segmentation fault* de SB3 al inicializar con el entorno real (construir el modelo sobre un entorno sintético y luego `set_env(real)`).

### 3 Proceso experimental

El desarrollo fue iterativo. En orden cronológico:

1. **Baseline antiguo.** Un PPO previo que solo conducía con una transformación *swap-negate* de la acción (`action_mode=wheels_fixed`);  $-869.9$  en `loop_obstacles`. Fallback inicial.
2. **PPO / DQN / SAC 20k.** Baselines de RL puro a 20k pasos; ninguno superó al baseline antiguo ( $-924$ ,  $-1005$ ,  $-1022$  respectivamente).
3. **PPO 50k (single-map).** Más pasos sin corregir nada: *peor* ( $-1481.8$ ).
4. **PPO multimap 50k.** Entrenado en los 5 mapas permitidos; tampoco ayudó ( $-1764.9$ , el peor).
5. **Auditoría técnica.** Revisión de código que reveló dos fallos críticos: la **doble normalización** de la CNN y el vocabulario discreto incoherente de DQN (Sección 4).

6. **Corrección de la doble normalización.** `src/cnn.py`: se elimina la división extra entre 255. Cambio decisivo.
  7. **PPO CNN-fix 50k.** Con la CNN corregida, el mismo PPO empieza a producir episodios completos con recompensa positiva (mejor *rollout* 1225.7), aunque su media sigue siendo negativa y muy dispersa.
  8. **Fine-tuning PPO CNN-fix 100k.** Partiendo del 50k se afinan 50k pasos adicionales (`--init-model`, `lr=5 · 10-5`, RL puro, solo `loop_empty`). Es el modelo final.
- `loop_obstacles` se usó **solo para evaluación**, nunca para entrenar.

## 4 Análisis de fallos

El hallazgo principal del proyecto es que varios resultados negativos no medían la calidad del agente, sino fallos del *pipeline*:

- **Mock silencioso.** La fábrica de entornos caía *en silencio* a un `MockDuckietownEnv` de **ruido aleatorio** si `gym_duckietown` no se registraba. *Fix*: `duckie_factory.py` falla explícito con `use_mock=False` (nunca cae al mock) e **importa `gym_duckietown` antes de `gym.make`** (ese import registra los IDs).
- **Render / vídeo.** `render()` daba framebuffer ruidoso bajo Xvfb. *Fix*: usar la observación RGB cruda que guarda `DuckieWrapper` en `last_rgb_frame` (`--video-source wrapper_rgb`); solo afecta a la visualización.
- **Convención de acciones del baseline.** El baseline antiguo solo conducía con `wheels_fixed` (su política quedó acoplada a una convención de ruedas). Para un agente entrenado desde cero la convención es indiferente; el modelo final usa `wheels` y **no** requiere truco alguno en evaluación.
- **Doble normalización de la CNN (crítico).** `CustomCNN.forward` dividía la entrada entre 255, pero SB3 *ya* normaliza las imágenes uint8 a `[0,1]` antes del extractor. La CNN recibía valores  $\sim 255$  veces más pequeños. Verificado en Colab:

```
preprocess_obs max: 0.7843137... # SB3 ya normaliza a [0,1]
after extra /255 max: 0.0030757... # la CNN recibia ~255x menos senal
```

*Fix*: `x = observations.float()` (sin /255). Afectaba a *todos* los algoritmos.

- **DQN con acciones discretas incoherentes.** `DISCRETE_ACTIONS` se diseñó con semántica `[v, δ]`, pero en `action_mode=wheels` se interpreta como `[vizq, vder]`: la acción “recto” `[0.6, 0.0]` se ejecuta como giro brusco. DQN **carece de un avance recto real**; queda como baseline **sospechoso/descartado**.
- **Presupuesto de entrenamiento limitado.** 20k–100k pasos desde píxeles es poco para Duckietown (suele requerir órdenes de magnitud más); contribuye a las medias negativas y a la varianza.

## 5 Resultados comparativos

Todas las cifras usan la infraestructura corregida (entorno real con fallo explícito, `model-first`); las cifras positivas reportadas antes de estos arreglos no se reproducían y quedan superadas. Métrica principal: recompensa en el mapa oculto `loop_obstacles`. La Tabla 1 recoge las **medias de evaluación** (`eval.py`) y la Tabla 2 separa los *best-of-10* cualitativos en vídeo.

| Modelo                                   | reward medio  | std    | long. media | observaciones                     |
|------------------------------------------|---------------|--------|-------------|-----------------------------------|
| Baseline antiguo ( <b>wheels_fixed</b> ) | −869.9        | 548.6  | 1264.4      | fallback inicial                  |
| PPO 20k ( <i>bug CNN</i> )               | −924.2        | 441.4  | —           | no supera baseline                |
| DQN 20k ( <i>bug CNN</i> )               | −1004.6       | 30.0   | —           | descartado (vocab. acción)        |
| SAC 20k ( <i>bug CNN</i> )               | −1021.7       | 81.4   | —           | no supera baseline                |
| PPO 50k single-map ( <i>pre-fix</i> )    | −1481.8       | 473.3  | 455.6       | más pasos no ayudan               |
| PPO multimap 50k ( <i>pre-fix</i> )      | −1764.9       | 712.8  | 460.0       | multimapa no ayuda                |
| PPO CNN-fix 50k                          | −2038.0       | 1408.0 | 1172.0      | rollouts positivos, alta varianza |
| <b>PPO CNN-fix 100k (ft)</b>             | <b>−487.6</b> | 1049.9 | 742.2       | <b>modelo final</b>               |

Table 1: Medias de evaluación en `loop_obstacles` (solo evaluación, nunca entrenamiento), `eval.py`, política determinista. “CNN-fix” = doble normalización corregida. El modelo final mejora la media del baseline antiguo (−487.6 vs −869.9). Para referencia, su evaluación en `loop_empty`:  $-1098.3 \pm 742.7 / 501.8$ .

| Modelo                              | mejor rollout | rollouts positivos completos | notas                         |
|-------------------------------------|---------------|------------------------------|-------------------------------|
| PPO multimap 50k ( <i>pre-fix</i> ) | −887.8        | 0 / 1                        | rollout aislado, 257 frames   |
| PPO CNN-fix 50k                     | 1225.7        | 2 / 10                       | alta varianza (−3445 a +1226) |
| <b>PPO CNN-fix 100k (ft)</b>        | <b>1249.5</b> | <b>6 / 10</b>                | mejor rollout, 1501 frames    |

Table 2: *Best-of-10* cualitativo en `loop_obstacles` (`make_eval_video.py`, `--video-source wrapper_rgb`). “rollouts positivos completos” = episodios que llegan al límite de pasos con recompensa acumulada positiva. El modelo final pasa de 2/10 (a 50k) a **6/10** (a 100k), con el mejor *rollout* en 1249.5.

**Lectura.** Antes del *fix*, todos los modelos rondaban −900 a −1800 de media y ningún *rollout* era positivo. Con la CNN corregida aparecen *rollouts* completos positivos; el fine-tuning a 100k sube la media de −2038 a −487.6 y los *rollouts* positivos de 2/10 a 6/10. La media sigue negativa por la **alta varianza**: el agente conduce bien a veces y se sale otras según la pose inicial.

## 6 Modelo final

El modelo entregado es `best_agent.zip`, copia de `ppo_cnnfix_loop_empty_100k_ft.zip`: un **PPO de RL puro** (50k + fine-tuning a 100k) entrenado en `loop_empty` con `action_mode=wheels` y la CNN con la normalización corregida.

**Justificación.** Es el mejor de la familia corregida y **mejora frente al baseline antiguo**: recompensa media −487.6 en `loop_obstacles` (vs −869.9) y **6 de 10** episodios completos con recompensa positiva. El **vídeo final** (best-of-10, cámara real `wrapper_rgb`) muestra el mejor *rollout* con recompensa 1249.527 y 1501 **frames** (vuelta completa sin salirse), en `delivery/final_agent_loop_obstacles.mp4`. Además, a diferencia del baseline antiguo, **carga y se evalúa sin ningún `--action-mode`** (usa `wheels` por defecto), lo que lo hace directamente compatible con el contrato del profesor.

**Pureza del enfoque.** El modelo final no usa `safe_discrete` (maniobras predefinidas), `v_omega_safe` (velocidad/giro acotados a mano), `forward_turn` (no implementado), PID ni controladores: aprende de la imagen a velocidades de rueda directas. Esas variantes se exploraron y se descartan por inyectar conocimiento de conducción.

## 7 Limitaciones y trabajo futuro

- **Alta varianza entre *resets*:** el desempeño depende mucho de la pose inicial (*rollouts* de +1249 a −1397). Es la limitación principal.
- **Más pasos de entrenamiento:** 50k–100k es poco; entrenar  $\geq 300\text{k}$ –1M pasos debería reducir la varianza y subir la media.
- **Ajuste de hiperparámetros:** p.ej. `ent_coef > 0` para más exploración, o *schedules* de `lr/clip`.
- **Revisión de DQN:** alinear el vocabulario discreto con la semántica de ruedas (incluir un avance recto real) para un baseline discreto honesto.
- **Vectorización real (SubprocVecEnv):** varios entornos en paralelo para hacer viable en tiempo el presupuesto alto; y envolver la evaluación con `Monitor` para métricas de episodio más limpias.

## Reproducibilidad

Dependencias: `requirements.txt` (`stable-baselines3==2.2.1`, `gymnasium==0.29.1`, `gym==0.25.2`, `torch==2.12.0`) + `gym-duckietown` aparte (`--no-deps`) + re-fijado `numpy==1.23.5` (detalle en `COLAB_SETUP.md`). Protocolo y tablas en `EXPERIMENTS.md`. El modelo final se entrena con `action_mode=wheels` y se evalúa *sin* `--action-mode`.

```
# Modelo final: PPO cnn-fix 50k + fine-tuning a 100k (RL puro, action_mode=wheels)
python train.py --algo ppo --map Duckietown-loop_empty-v0 --timesteps 50000 \
    --output ppo_cnnfix_loop_empty_50k --init-order model-first
python train.py --algo ppo --map Duckietown-loop_empty-v0 --timesteps 50000 \
    --output ppo_cnnfix_loop_empty_100k_ft \
    --init-model models/ppo_cnnfix_loop_empty_50k --learning-rate-override 5e-5 \
    --init-order model-first
```

```
# Evaluacion en el mapa oculto (SOLO evaluacion) y video (camara real)
python eval.py --algo ppo --model best_agent.zip \
    --map Duckietown-loop_obstacles-v0 --allow-eval --init-order model-first --device cpu
python scripts/make_eval_video.py --algo ppo --model best_agent.zip \
    --map Duckietown-loop_obstacles-v0 --allow-eval \
    --video-source wrapper_rgb --rollouts 10 --init-order model-first
```